

基于大模型的测试场景生成与智能测试工具

□ 简介

- ✓ 随着 Web Agent 快速发展，人们对其在复杂 Web 应用中的测试可用性提出了更高要求
- ✓ 现有 Web Agent 在 WebArena 等基准上仍表现出较高的任务失败率，**原因**在于：
 - 1. Web 应用**业务逻辑复杂**且高度领域化
 - 2. 大模型存在幻觉，且**缺乏**待测应用的**领域知识**，容易输出与事实不符的信息
 - 3. 难以在执行完操作后**准确判定**任务是否成功
- ✓ **软件文档（如用户手册）** 蕴含大量业务知识，可帮助 Agent 更好地理解功能、判断执行结果
- ✓ 本课程实践旨在设计一种**基于大模型的测试场景生成与自主执行工具**
 - 1. 自动提取用户手册中的知识，生成功能覆盖全面、粒度适宜、具有可执行性的测试场景
 - 2. 基于大模型智能体，自主执行测试场景，对目标应用开展全面的功能测试

任务

□ 任务一：基于用户手册的测试场景自动生成

- ✓ 目标：基于大模型检索增强技术（RAG），从用户手册中提取知识，生成测试场景
- ✓ 要求
 - 能够根据用户手册提取软件的主要功能点
 - 根据每个功能点能够生成结构化的测试场景
 - 支持功能点、测试场景的可视化展示
- ✓ 测试场景
 - 构成：[[step]+ [expectation]?]+
 - 操作步骤：完成功能所需的具体操作步骤
 - 预期状态：功能完成后的预期状态，相当于测试预言，包含用于评估功能是否成功完成的关键特征

任务

□ 任务二：测试场景驱动的智能测试智能体

- ✓ 目标：构建基于大模型的 Web 测试智能体，自动执行任务一生成的测试场景
- ✓ 架构需至少包含以下要素（可自主扩展）：
 - 规划：根据测试场景自主规划执行计划
 - 记忆：辅助执行的上下文信息
 - 执行：与浏览器交互，执行规划动作
 - 验证：根据整个测试轨迹验证测试场景是否执行成功，该功能是否正确

评分标准

□ 【基础功能档】

- ✓ **任务一：** 根据用户手册能够识别主要功能点，并生成主要功能的测试场景，测试场景的生成格式符合要求
- ✓ **任务二：** 智能体能够执行任务一中识别的简单测试场景，能够验证执行完整性与功能正确性

评分标准

□【提升创新档】

✓ 任务一

- 生成测试场景的正确性与全面性：确保从用户手册等文档中检索到的信息真实有效，尽量避免大模型“幻觉”导致的错误；尽可能全面地覆盖文档中包含的功能并避免遗漏
- 生成测试场景的粒度与可执行性：功能划分的粒度应合适，既不能过细导致难以组合成实际功能，也不宜过粗以致无法指导具体操作；同时保证生成的用户故事具有可执行性，即能够被现有的 Web 测试智能体有效执行

✓ 任务二

- 测试场景执行的通过率与稳定性：提升智能体执行测试场景的准确率，对于简单、中等难度测试场景能够正确通过，甚至通过部分困难场景；此外，也可考虑提升智能体执行的效率
- 支持对测试场景进行变异，能够识别典型的应用错误（包括：执行异常、布局问题、语义错误等）
- 测试场景验证：能够根据执行轨迹正确识别执行结果（成功与失败），对于执行失败准确输出失败原因

鼓励所有的创新方法设计以及评估策略设计（评估方法与指标）等等

补充

□ 目标 Web 应用为 4gaboards

- ✓ 用户手册地址: <https://docs.4gaboards.com/>
- ✓ 应用 demo 地址: <https://demo.4gaboards.com/>

□ 计算设备: 对于个人计算设备的计算能力无特殊要求, 能完成赛题即可

□ 软件依赖: 编程语言及所用技术不限; 需使用版本控制工具 (Git 等)

□ 大模型: 国产大模型 GLM-4.6V/4.7、Qwen3-VL-Plus、DeepSeek V3

Q&A

THANK YOU!